

补充材料

基于扩散概率模型的高精度高自由度超表面逆向设计

张泽洲、杨传川*、秦一峰*、冯浩、冯继强、李洪斌

1. 详细公式推导

在此，我们基于扩散概率理论，对公式3、公式6-7、公式8及公式10进行了详细推导。^[1]

1.1. 方程3

通过采用公式1中的重参数化技巧并定义 $\alpha_t = 1 - \beta_t$, $\alpha_t = \prod_{s=1}^t \alpha_s$, 在任意时间步 t 处的噪声元原子矩阵 x_t 可直接基于 x_0 表示为闭式公式:

$$\begin{aligned} x_t &= \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \cdot \epsilon \\ &= \sqrt{\alpha_t} x_{t-1} + \sqrt{1 - \alpha_t} \cdot \epsilon \\ &= \sqrt{\alpha_t} (\sqrt{\alpha_{t-1}} x_{t-2} + \sqrt{1 - \alpha_{t-1}} \cdot \epsilon) + \sqrt{1 - \alpha_t} \cdot \epsilon \\ &= \sqrt{\alpha_t \alpha_{t-1}} x_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \cdot \epsilon \\ &\dots \\ &= \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \cdot \epsilon \end{aligned} \tag{S1}$$

1.2. Equation 6-7

$$\begin{aligned} \mathbb{E}_{q(x_{1:T} | x_0)} [-\log p_\theta(x_0)] &\leq \mathbb{E}_{q(x_{1:T} | x_0)} [-\log p_\theta(x_0)] + D_{KL}(q(x_{1:T} | x_0) \| p_\theta(x_{1:T} | x_0)) \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_0) + \log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{1:T} | x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_0) + \log \frac{q(x_{1:T} | x_0)}{(p_\theta(x_0 | x_{1:T}) p_\theta(x_{1:T})) / p_\theta(x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_0) + \log \frac{q(x_{1:T} | x_0)}{p_\theta(x_0, x_{1:T}) / p_\theta(x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_0) + \log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{0:T}) / p_\theta(x_0)} \right] \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_0) + \log \frac{q(x_{1:T} | x_0)}{p_\theta(x_{0:T})} + \log p_\theta(x_0) \right] \\ &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} \right] =: L \end{aligned} \tag{S2}$$

The variational lower bound L can be further simplified as L_T, L_{t-1}, L_0 :

$$\begin{aligned}
L &= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log \frac{p_\theta(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t)}{\prod_{t=1}^T q(x_t | x_{t-1})} \right] \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_t | x_{t-1})} \right] \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 2} \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_t | x_{t-1})} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 2} \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_t | x_{t-1}, x_0)} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 2} \log \frac{p_\theta(x_{t-1} | x_t) q(x_{t-1} | x_0)}{q(x_{t-1} | x_t, x_0) q(x_t | x_0)} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \tag{S3} \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 2} \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} - \log \frac{q(x_1 | x_0)}{q(x_T | x_0)} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T} | x_0)} \left[-\log \frac{p_\theta(x_T)}{q(x_T | x_0)} - \sum_{t \geq 2} \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} - \log p_\theta(x_0 | x_1) \right] \\
&= \mathbb{E}_{q(x_T | x_0)} \left[-\log \frac{p_\theta(x_T)}{q(x_T | x_0)} \right] - \sum_{t \geq 2} \mathbb{E}_{q(x_t, x_{t-1} | x_0)} \left[\log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} \right] - \mathbb{E}_{q(x_1 | x_0)} [\log p_\theta(x_0 | x_1)] \\
&= \underbrace{D_{KL}(q(x_T | x_0) \| p_\theta(x_T))}_{L_T} + \sum_{t \geq 2} \underbrace{\mathbb{E}_{q(x_t | x_0)} [D_{KL}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t))]}_{L_{t-1}} - \underbrace{\mathbb{E}_{q(x_1 | x_0)} [\log p_\theta(x_0 | x_1)]}_{L_0}
\end{aligned}$$

是一个不包含任何可学习参数的常数，因此在训练过程中可以忽略。 L_0 表示在获得 x_1 后重建 x_0 的单一步骤，对 L 的影响较小。因此， L 的主要决定因素是 L_{t-1} 。值得注意的是，在 q 中引入附加条件 $q(x_t | x_{t-1}) = q(x_t | x_{t-1}, x_0)$ 由于马尔可夫性质不会改变结果。

1.3. 方程8

在 L_{t-1} ，后验 $q(x_{t-1} | x_t, x_0)$ 可表示为：

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \mu_t(x_t, x_0), \beta_t) \tag{S4}$$

可以利用贝叶斯法则扩展公式：

$$\begin{aligned}
q(x_{t-1} | x_t, x_0) &= q(x_t | x_{t-1}, x_0) \frac{q(x_{t-1} | x_0)}{q(x_t | x_0)} \\
&= \frac{\mathcal{N}(x_t; \sqrt{\alpha_t} x_{t-1}, \beta_t \mathbf{I}) \mathcal{N}(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1}) \mathbf{I})}{\mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) \mathbf{I})} \\
&\propto \exp\left(-\frac{1}{2} \left(\frac{(x_t - \sqrt{\alpha_t} x_{t-1})^2}{\beta_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right)\right) \\
&= \exp\left(-\frac{1}{2} \left(\frac{x_t^2 - 2\sqrt{\alpha_t} x_t x_{t-1} + \alpha_t x_{t-1}^2}{\beta_t} + \frac{x_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}} x_0 x_{t-1} + \bar{\alpha}_{t-1} x_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right)\right) \\
&= \exp\left(-\frac{1}{2} \left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) x_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t} x_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) x_{t-1} + C(x_t, x_0) \right)\right)
\end{aligned} \tag{S5}$$

其中 $C(x_t, x_0)$ 可以忽略，因为它与 x_t 无关，并基于高斯函数公式，可推导出方差与均值表达式：

$$\begin{aligned}
\tilde{\beta}_t &= 1 / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) = 1 / \left(\frac{\alpha_t - \bar{\alpha}_t + \beta_t}{\beta_t (1 - \bar{\alpha}_{t-1})} \right) = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t \\
\boldsymbol{\mu}_t(x_t, x_0) &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \\
&= \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} x_0 \\
&= \frac{\sqrt{\alpha_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \left(\frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_t) \right) \\
&= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_t \right)
\end{aligned} \tag{S6}$$

我们可以定义 $\Sigma_\theta(x_t, t) = \tilde{\beta}_t$ ，并基于KL散度公式^[2, 3]：

$$\begin{aligned}
L_\theta &\propto \mathbb{E}_{q(x_t | x_0)} [D_{KL}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t))] \\
&= \mathbb{E}_{q(x_t | x_0)} \left[\frac{1}{2} \left[\log \frac{\det \tilde{\beta}_t}{\det \tilde{\beta}_t} - n + \text{tr}(\tilde{\beta}_t^{-1} \tilde{\beta}_t) + (\boldsymbol{\mu}_\theta(x_t, t) - \tilde{\boldsymbol{\mu}}_t(x_t, x_0))^T \tilde{\beta}_t^{-1} (\boldsymbol{\mu}_\theta(x_t, t) - \tilde{\boldsymbol{\mu}}_t(x_t, x_0)) \right] \right] \\
&= \mathbb{E}_{q(x_t | x_0)} \left[\frac{1}{2} \left[\log 1 - n + n + (\boldsymbol{\mu}_\theta(x_t, t) - \tilde{\boldsymbol{\mu}}_t(x_t, x_0))^T \tilde{\beta}_t^{-1} (\boldsymbol{\mu}_\theta(x_t, t) - \tilde{\boldsymbol{\mu}}_t(x_t, x_0)) \right] \right] \\
&= \mathbb{E}_{q(x_t | x_0)} \left[\frac{1}{2 \tilde{\beta}_t} \| \boldsymbol{\mu}_\theta(x_t, t) - \tilde{\boldsymbol{\mu}}_t(x_t, x_0) \|^2 \right]
\end{aligned} \tag{S8}$$

其中 $\boldsymbol{\mu}_\theta$ 用于近似 $\boldsymbol{\mu}_t$ ，可表示为：

$$\boldsymbol{\mu}_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) \tag{S9}$$

通过插入 $\boldsymbol{\mu}_t$ 和 $\boldsymbol{\mu}_\theta$ 该培训流程可简化为：

$$\begin{aligned}
\arg \min_{\theta} L &= \arg \min_{\theta} \mathbb{E}_{q(x_t | x_0)} \left[\frac{1}{2\tilde{\beta}_t} \|\mu_{\theta}(x_t, t) - \tilde{\mu}_t(x_t, x_0)\|^2 \right] \\
&= \arg \min_{\theta} \mathbb{E}_{q(x_t | x_0)} \left[\frac{1}{2\tilde{\beta}_t} \left\| \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right) - \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_t \right) \right\|^2 \right] \quad (\text{S10}) \\
&= \arg \min_{\theta} \mathbb{E}_{q(x_t | x_0)} \left[\frac{(1-\alpha_t)^2}{2\tilde{\beta}_t \alpha_t (1-\bar{\alpha}_t)} \|\epsilon_{\theta}(x_t, t) - \epsilon_t\|^2 \right] \\
&\propto \arg \min_{\theta} \mathbb{E}_{q(x_t | x_0)} \left[\|\epsilon_{\theta}(x_t, t) - \epsilon_t\|^2 \right]
\end{aligned}$$

1.4. 方程10

x_{t-1} 可根据公式S4、公式S6、公式S7和公式9进行重新参数化：

$$\begin{aligned}
x_{t-1} &= \tilde{\mu}_t(x_t, x_0) + \tilde{\beta}_t \cdot z, \\
&= \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \tilde{\epsilon}_{\theta}(x_t, t, c) \right) + \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \cdot \beta_t \cdot z, z \sim \mathcal{N}(0, 1) \quad (\text{S11})
\end{aligned}$$

2. MetaDiffusion训练与生成算法

Algorithm S1 MetaDiffusion Training

Input: pixelated geometry, corresponding S-Parameters and extra parameters Dataset $\{X, S, W1, H2, N2\}$, probability of unconditional training p_{uncond} , total step T

1: **repeat**

2: Sample $x_0 \sim X$

3: Sample condition $c \sim \{S, W1, H2, N2\}$

4: Randomly dropout condition $c \leftarrow \emptyset$ with probability p_{uncond}

5: Sample $t \sim \text{Uniform}(\{1, \dots, T\})$, and $\epsilon \sim \mathcal{N}(0, I)$

6: Compute x_t using closed form Equation 3: $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$

7: Take gradient descent step on $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(x_t, c, t)\|^2$

8: **until** converged

在训练阶段，如算法1所示，首先从训练集中采样元原子 x_0 。然后，从训练集中采样其对应的S参数和附加参数（元原子尺寸 $W1$ 、厚度 $H2$ 、材料折射率 $N2$ ），并将这些参数拼接为一个 1×55 向量作为条件输入。然后，以10%的概率，我们将条件输入替换为无条件标记0。由于实际训练是在整个批次上进行的，这相当于随机选择10%的样本进行无条件训练。对于每个样本，我们随机选择一个时间步进行前向扩散，并根据公式3添加噪声，直接获得对应时间步的噪声数据 ϵ_t 。我们保存所添加的噪声 ϵ 作为神经网络的训练标签。


将噪声数据 x_t 、条件输入及时间步长共同输入神经网络，神经网络输出估计噪声结果。 ϵ_θ 神经网络输出之间的均方误差（MSE） ϵ_θ 噪声标签 ϵ 该值作为模型损失计算，并通过反向传播用于训练MetaDiffusion网络。

Algorithm S2 MetaDiffusion Generating

Input: required S-Parameters and extra parameters condition c , guidance strength w , well-trained network ϵ_θ
 Sample $x_T \sim \mathcal{N}(0, I)$
 2: **for** $t = T, \dots, 1$ **do**
 Mix conditional and unconditional results $\tilde{\epsilon}_t = (1 + w)\epsilon_\theta(x_t, c) - w\epsilon_\theta(x_t, 0)$
 4: Sample $z \sim \mathcal{N}(0, I)$ if $t > 1$, else $z = 0$
 Compute x_{t-1} as Equation 10: $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}} \tilde{\epsilon}_t \right) + \tilde{\beta}_t z$
 6: **end for**
return x_0 as generated geometry

在生成阶段，如算法2所示，我们首先从高斯分布中采样 x_T 。然后，我们将 x_T 和条件 c 输入网络以获得条件预测结果。同时，我们还将 x_T 和无条件标记0输入网络以获得无条件预测结果。条件 $\epsilon_\theta(x_T, s)$ 无条件的 $\epsilon_\theta(x_T)$ 根据公式9，预测结果以 w 的比例混合，作为网络的最终预测。最终预测结果用于公式10以获得 x_{T-1} ，并从时间步 t 开始重复上述过程= T 到时间步 $t=1$ 。随着时间步长的减小，我们逐渐获得噪声更低的生成结果，且分布逐渐接近目标分布。当 $t=1$ ，我们设定 $z=0$ 并获取输出的新元原子 x_0 。

3. Meta扩散网络结构



图S1.特定网络结构

从输入数据开始，我们通过残差块从原始超曲面结构 x_t 中提取特征，将输入维度从 $(1 \times 32 \times 32)$ 提升至 $(256 \times 32 \times 32)$ 。随后使用两个下采样块将张量维度缩减至 $(512 \times 8 \times 8)$ ，最后通过 GELU 池化层将数据向量化为 $(512 \times 1 \times 1)$ ，构成U-Net结构的瓶颈。值得注意的是，在下采样过程中，随着矩阵分辨率降低，通道数量会增加以实现多维特征的提取。接着通过三个上采样块逐步将维度提升至 $(256 \times 32 \times 32)$ 。具体而言，第一个上采样块采用 8×8 卷积核的转置卷积，后续两个上采样块则使用 2×2 卷积核的转置卷积。每个上采样块均接收来自对应下采样块的残差连接。与此同时，时间步长 t 和条件 c 由特征提取层处理以获取嵌入特征。这些条件的嵌入特征随后输入上采样模块，引导模型根据当前时间步长 t 和对应条件进行估计。最终，上采样模块的输出与原始输入 x_0 的跳跃连接进行融合，以进一步减少下采样和上采样过程中的信息损失。经过两个卷积层（卷积核大小3、步长1、填充1）后，通道数被缩减为单通道作为最终输出，该最终层采用组归一化和ReLU激活函数。

每个下采样模块首先使用残差块进行特征提取，随后通过池化层实现降维。上采样模块则采用转置卷积层进行维度提升，最后通过两个残差块完成特征恢复。用于预处理时间步 t 和条件 c 的嵌入式特征提取层由两个全连接层组成，中间连接一个 GELU 激活函数。残差块包含两个卷积层（卷积核大小3，步长1，填充1）、批归一化和 GELU 激活，其中第一个卷积块的输出作为跳跃连接与第二个卷积块的输出相加，再除以1.414得到最终输出。

4. 超参数

β_t 表示时间步长 t 处的分布偏移量，直观理解为第 t 个时间步长添加的噪声量。根据公式 $3x_t = \sqrt{\bar{\alpha}_t} x_0 + \epsilon \sqrt{1 - \bar{\alpha}_t}$ ，在哪里 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ ，需要持续增加 β_t 以使 $\sqrt{\bar{\alpha}_T} x_T$ 的均值趋近于0，且方差 $\sqrt{1 - \bar{\alpha}_T}$ 接近1。在噪声添加过程的初期阶段，元原子模式矩阵所含噪声较少，因此少量噪声就会产生显著影响，导致所包含信息的快速衰减。在后期阶段，由于已有更多噪声被引入，新增噪声的影响

减少。因此，在持续需要添加噪声的条件下，初始轮次中添加的噪声较少，后期添加更多噪声以减缓信息损失率。因此， β_1 从 $1e-4$ 开始线性增加至 $\beta_T=0.02$ 。此外，总时间步长 T 的选择涉及权衡，较大值可提高生成质量但需要更长的推理时间。本研究出于通用性考虑，直接选择 $T=500$ 而未进行进一步微调。然而在未来工作中，若通过实验寻找最优超参数 T ，有望获得更优结果。

为确保普适性，我们直接采用扩散模型训练参数的常规配置，无需通过精细筛选进行额外优化，以此证明该方法具有良好的鲁棒性，并能轻松推广至不同数据场景。具体而言，我们选用Adam优化器，学习率为 $1e-4$ ，采用简单线性衰减策略，批量大小设为64。根据广泛使用的标准，我们将数据集按8:1:1的比例划分为训练集、验证集和测试集。训练集用于模型训练，验证集用于评估训练过程中的每轮训练效果，测试集用于最终模型性能比较。我们使用 36×36 数据集中像素矩阵左上角的二维布尔矩阵作为原始结构信息 x 。我们从对应的传输响应的实部和虚部中各采样26个点，并将它们拼接成一个 1×52 一维向量 s 。随后将 S 参数向量与一个1连接 $\times 3$ 一维向量 I 用于表征结构参数（厚度、折射率、基底尺寸）以形成 1×55 一维向量作为输入条件 c 。生成网络的目标是生成一个满足条件 c 要求的元原子结构 x' 。

5. 代理求解器 PNN


PNN^[4]由多个卷积层和一个NTN层构成^[5]。NTN层负责从一维参数矩阵中提取信息，相较于全连接层，它通过多切片方式从一维向量中捕获更多内在信息。卷积层则负责从二维自由结构矩阵中提取特征。在融合一维和二维特征后，多个卷积层用于进一步处理。最后，全连接层对频率响应的实部或虚部进行回归分析。

我们采用二维自由形式结构矩阵和一维附加参数向量作为输入，其中一维附加参数向量用于指定元原子的材料、尺寸和厚度。 S 参数的实部和虚部被用作

训练两个网络分别预测实部和虚部的标签。PNN 网络在训练集上进行训练，验证集则作为训练过程中的监控数据，用于评估收敛性和过拟合情况。最终将训练好的 PNN 应用于测试集进行性能评估。我们采用均方误差（MSE）作为损失函数：


$$L_{PNN} = \frac{1}{N} \sum_{n=1}^N (s_n - s'_n)^2,$$

其中 s_n 表示通过CST模拟获得的真实标签， s'_n 表示 PNN 预测的结果。



图S2.前向预测网络 PNN 训练过程中训练集与验证集的损失值。

图S1展示了训练过程中训练集和验证集的误差变化。我们采用余弦学习率调整策略来帮助网络跳出局部最优解，因此损失值会随学习率周期性波动。但可以明显看出，网络在验证集上逐渐收敛，表明训练已足够充分。将训练好的网络应用于测试集进行性能评估，最终获得0.的误差值。实部为0.001835，虚部为0.001789。此外，在图S2中，我们随机选取样本并使用 PNN 进行前向预测，与模拟真实值进行对比。PNN 网络的预测结果与数值模拟获得的真实结果高度吻合。



图S3.PNN 的定性示例。

表S1展示了MetaDiffusion、基于GAN和基于 VAE 模型的 MSE 误差，并与 PNN 的 MSE 误差进行对比。结果表明， PNN 引入的潜在误差显著小于MetaDiffusion、基于GAN和基于 VAE 模型之间的性能差异。因此， PNN 足以准确评估这三种模型之间的性能差异。

表S1：模型测试误差

模型	MSE
PNN（实部）	0.001835
PNN（虚部）	0.001789
PNN（两份均值）	0.001812
SLMGAN	0.01084
WGAN-GP	0.01466
循环变分自编码器	0.01675
MetaDiffusion（提议）	0.005743

表S2提供了 PNN 的训练与推理时间，并对比了使用CST Studio Suite频域求解器在同一模型上进行模拟所需的时间。

CPU。从表格中可以看出， PNN 需要65小时的训练时间。但在推理阶段，其速度明显快于CST求解器。因此，当处理大量元原子时， PNN 比CST求解器更高效。

表S2： PNN 与CST求解器的时间对比

模型	训练时间（1300个周期）	推断时间（每原子）
PNN	65小时	0.001秒
CST频域求解器	-	149秒

6. 比较法

对于配备模拟器的 SLMGAN ，由于缺乏官方开源实现代码，我们根据文章提供的细节尽可能精确地复现了该模型。为确保关键步骤Sinkhorn散度的准确性，我们采用Geom-Loss库^[6]中的标准PyTorch API进行计算。此外，在引入对称信息时，我们通过将生成的二维结构与其转置矩阵相加，再按照原论文所述方法进行插值处理。在模型架构方面，原论文中的数据集使用了18×18矩阵作为超表面图案表示。为适应我们更高精度的64×64模式表示中，我们基于原始架构提升了生成器中PixelShuffle模块的上采样因子及对应上采样模块的通道数。对于判别器，我们仅调整最后一个卷积核的参数以适应尺寸差异。此外， SLMGAN 需要引入一个经过预训练的精确前向网络模拟器作为训练误差之一。由于该 PNN 已被证明是可靠的替代求解器，因此可直接使用经过充分训练的模型。同时，我们采用了论文推荐的训练参数设置，包括学习率1e-2并使用Adam作为优化器。

对于 WGAN -GP，我们采用了一个具有代表性的开源实现^[7]作为基础模型结构。通过调整卷积核和全连接层的参数，使其适配数据集的输入尺寸。此外，我们在生成器和判别器中均添加了针对输入条件向量的额外特征提取层，以进一步增强网络的能力。

对于条件变分自编码器（cVAE），我们采用代表性研究^[8]作为基础模型架构。通过调整卷积核和全连接层的参数，使其适配数据集的输入尺寸。

7. 模型的时间信息

表S3展示了四个模型在每个训练周期的耗时数据。此外，表中还对比了四个模型在验证集上达到MAE误差0.05和0.03所需的训练时间。从表S3可以看出，虽然MetaDiffusion每个训练周期耗时比基于GAN的方法更长，但其收敛所需的训练周期更少。因此，在达到相同误差时，MetaDiffusion所需的总训练时间比其他两种基于GAN的方法更短。另一方面，尽管cVAE每个训练周期的训练速度更快，但其误差率却高于MetaDiffusion和基于GAN的方法，表明其学习能力相对较弱。综上所述，我们提出的MetaDiffusion模型展现出高效性。

表S3：模型训练时间。一个周期的训练数据量为174483*0.8=139906。缺失值表示相应方法的验证误差未能持续低于对应误差值。


模型	时间（每周期）	时间（Val Loss降至0.05）	时间（Val Loss降至0.03）
伴弥散	196秒	49个时段 * 196 = 9604秒	210个周期 * 196 = 41160秒
SLMGAN	159秒	362个周期 * 159 = 57558秒	-
WGAN-GP	112秒	327个时段 * 112 = 36624秒	-
循环变分自编码器	44秒	-	-

在本研究中，我们的主要目标是提升模型的生成精度和训练稳定性，而非优化生成过程。具体而言，我们采用从高斯噪声开始的单时间步序贯去噪方法来生成结构。这需要T个去噪步骤，导致每个原子的生成速度为0.43秒，相较于SLMGAN、WGANGP和cVAE的4.7e-5、7.8e-5和7.4e-5秒速度稍显缓慢。不过，MetaDiffusion的生成速度仍有提升空间。在后续研究中，我们计划基于MetaDiffusion模型的训练成果，整合多步去噪策略^[9]等先进技术，进一步优化生成阶段的性能。这种集成可显著减少生成过程中所需的去噪步骤，从而大幅加快生成过程。

8. 训练数据外频率范围的迁移学习

迁移学习方法可利用极小规模数据集，以最低成本使模型泛化至训练数据之外的频段。以20-30 THz频段为例：首先采集少量标注数据（如1000个样本，约占原始训练数据的0.07%），随后采用比常规学习率低一个数量级（1e-5）的参数进行微调。

初始训练速率。该模型仅经过50个训练周期（10分钟训练时间）的微调。在测试集上，平均绝对误差（MAE）为0.04095，平均绝对误差（MSE）为0.0033。此外，图S1还展示了20-30THz频段的一对多生成结果。用于代理求解器的 PNN 同样基于20-30THz频段超过50,000个标注数据点进行训练以确保准确性，测试集上的 MSE 为1.64e-6。



图S4.20-30THz频段的一对多代数结构。生成了多个满足20-30THz给定S参数目标的单元胞结构。

参考

- [1] J. Ho、A. Jain、P. Abbeel, 载于《神经信息处理系统进展》, Curran Associates, Inc., 2020年。
- [2] J. Duchi, *加利福尼亚州伯克利* 2007, 3, 2325.
- [3] C. 罗, arXiv预印本 arXiv:2208.11970 2022。
- [4] S. An, B. Zheng, M. Y. Shalaginov, H. Tang, H. Li, L. Zhou, J. Ding, A. M. Agarwal, C. Rivero-Baleine, M. Kang, K. A. Richardson, T. Gu, J. Hu, C. Fowler, H. Zhang, *Opt. Express* 2020, 28, 31932.
- [5] R. Socher、D. Chen、C. D. Manning、A. Ng, 载于《神经信息处理系统进展》, Curran Associates, Inc., 2013年。
- [6] J. Feydy, T. Sejourne, F.-X. Vialard, S. Amari, A. Trouve, G. Peyre, in *第二十二届国际人工智能与统计会议论文集*, PMLR , 2019, pp. 2681–2690.
- [7] J. Jiang, D. Sell, S. Hoyer, J. Hickey, J. Yang, J. A. Fan, *ACS Nano* 2019, 13, 8872.
- [8] W. Ma, F. Cheng, Y. Xu, Q. Wen, Y. Liu, *高级材料* 2019,31,1901111.
- [9] J. Song, C. Meng, S. Ermon, arXiv预印本 arXiv:2010.02502 2020.