

研究文章

张泽洲、杨传川*、秦一峰*、冯浩、冯继强、李洪斌

基于扩散概率模型的高精度高自由度超表面反演设计

<https://doi.org/10.1515/nanoph-2023-0292>

2023年5月16日收到; 2023年9月22日接受; 2023年10月4日在线发表

摘要: 传统超材料元原子设计方法高度依赖研究者的先验知识和全波模拟试错过程, 导致流程耗时且效率低下。基于优化算法(如进化算法)和拓扑优化的逆向设计方法已被引入超材料设计领域, 但这些算法均无法满足多目标任务的通用性需求。近期, 以生成对抗网络(GAN)为代表的深度学习方法被应用于超材料逆向设计, 能够根据S参数要求直接生成高自由度元原子。然而, GAN的对抗训练过程会导致网络不稳定并产生高昂的建模成本。本文提出一种基于扩散概率理论的新型超材料逆向设计方法。通过学习将原始结构转换为高斯分布的马尔可夫过程, 该方法能够逐步从高斯分布中去除噪声, 并生成新的高自由度

该方法通过筛选符合S参数条件的元原子, 有效规避了生成对抗网络(GAN)对抗训练过程引发的模型不稳定性, 从而确保生成结果的准确性与高质量。实验数据表明, 相较于现有GAN主流方法, 本方法在模型收敛速度、生成精度及图像质量方面均展现出显著优势。

关键词: 深度学习; 元曲面; 逆向设计; 扩散概率模型

1 引言

流行的超材料/功能超表面设计涉及由设计者直觉引导的试错迭代过程, 设计者选择单元胞结构, 进行参数扫描, 并创建阵列以实现特定功能[1–6]。然而, 该方法效率低下, 且由于非线性增加而难以处理宽带多频目标[7]。最近, 基于优化的逆向设计方法(如基于伴随的拓扑优化[8]、遗传算法[9]和蚁群优化[10])已出现, 但它们无法处理多目标任务, 且由于针对不同目标单元进行单独优化而导致计算成本较高。

与基于优化的逆向设计方法相比, 深度学习能够有效探索全局设计空间[11], 使得只需单次训练即可快速生成满足S参数要求的元原子结构并实现复用。早期研究采用串联式方法连接正向与逆向网络来解决一对多问题, 通过一维向量中的固定结构参数进行逆向设计[12–16]。随着性能要求的提升, 研究者开始探索具有更高自由度的自由形式结构, 并引入生成对抗网络(GAN) [17] 以及变分自编码器(VAE) [18] 作为生成方法。

***通讯作者: 杨传川**, 北京大学电子学院先进光通信系统与网络国家重点实验室, 北京100871, 中国, 电子邮箱: yangchuanchuan@pku.edu.cn; **秦一峰**, 彭程实验室

Shenzhen 518055, China, E-mail: qinyf@pcl.ac.cn.

<https://orcid.org/0000-0003-1221-8093>

张泽洲和冯浩, 北京大学深圳研究生院, 中国深圳518055; 彭程实验室, 中国深圳518055; 北京大学电子学院先进光通信系统与网络国家重点实验室, 中国北京100871

电子邮箱: zezhou.zhang@stu.pku.edu.cn (张泽), hfeng@pku.edu.cn

(H. Feng) <https://orcid.org/0009-0002-6834-6588> (Z. Zhang)

冯继强, 深圳大学数学科学学院,

中国深圳518060, 电子邮箱: fengjq@szu.edu.cn

李洪斌, 北京大学电子学院先进光通信系统与网络国家重点实验室,

中国北京 100871, 电子邮箱: lihb@pku.edu.cn

VAEs由于在重建损失与KL散度损失之间进行权衡[7, 19], 会产生模糊、低质量的结果, 并且需要额外的优化算法进行广泛的潜在空间搜索[20–22], 从而增加设计复杂性。GANs通过生成器与判别器之间的对抗训练[23], 能够直接生成高质量结构。条件GANs通过提供条件输入来引导网络, 并已应用于多种场景, 如超表面[24–27]、一维超栅格[11]、自由形态超栅格[28, 29]、传输表面[30]、纳米结构[31]、结构色[32]以及单频XY极化复用表面[33]。

然而, GAN的对抗训练过程需要在整个训练过程中保持生成器与判别器能力之间的动态平衡, 这具有挑战性。因此, GAN在训练过程中会遇到固有的收敛困难, 最终影响其生成准确结构的能力。尽管尝试通过深度卷积GAN (DCGANs) [34]、Wasserstein GAN (WGANs) [35]以及带梯度惩罚的WGAN (WGAN-GP) [36]等方法来缓解不稳定性, 但对抗过程固有的不稳定性仍未解决。模型的稳定性和准确性仍然依赖于训练期间精心设计的模型结构和超参数选择[37]。当输入和输出维度发生变化时, 需要进行大量实验来调整模型结构, 这增加了网络设计成本并限制了GAN在各种场景中的适用性[38]。

最近, 扩散概率理论[39]在图像生成任务中展现出优于生成对抗网络 (GANs) 的性能, 其生成样本在准确性、多样性和精确性方面均表现更优[38]。因此, 该理论已成功应用于文本到图像生成领域, 包括OpenAI的dalle [40]、Google的IMAGEN [41]以及图像超分辨率[42]。然而, 将扩散概率理论作为新型生成方法用于按需直接逆向生成超曲面的应用尚未被探索。

在本文中, 我们提出了一种基于扩散概率模型的新型超表面逆向设计方法, 称为MetaDiffusion, 能够根据宽带幅度和相位要求直接生成具有高自由度的自由曲面超原子结构。如图1所示, 我们的方法通过逐步向超原子 x_0 添加噪声, 直到其变为 x_T ($q(x_t|x_{t-1})$ 中的高斯噪声) 来启动正向马尔可夫过程。然后, 神经网络 $p_\theta(x_{t-1}|x_t)$ 近似去噪过程 $q(x_{t-1}|x_t)$, 通过迭代地对高斯分布中的采样 x_T 进行去噪, 生成新的结构

x' 符合S参数要求。这消除了GAN所采用的不稳定对抗过程。因此, MetaDiffusion无需针对不同数据对稳定网络和超参数进行微调, 可轻松应用于各种超表面设计任务。我们还将S参数与附加参数 (元原子尺寸 $W1$ 、厚度 $H2$ 、材料折射率 $N2$) 作为条件融合到模型的解码器中, 并采用无分类器的条件控制策略[43], 实现了宽带S参数目标的精准直接生成。

据我们所知, 我们是首个将扩散概率模型应用于元原子逆向设计的研究团队, 成功克服了生成对抗网络 (GAN) 对抗过程的不稳定性。我们的方法MetaDiffusion整合了S参数条件, 并在神经网络中采用无分类器的条件控制策略, 从而根据S参数要求实现精准生成。重要的是, 通过严格测试, 我们证明与基于GAN的方法 (如SLMGAN [44]和WGAN-GP) 相比, 所提出的方法收敛更快、条件精度更高且稳定性更强。具体而言, 对于30至60 THz频段内包含52个采样点的宽带S参数目标, 我们的方法在S参数平均绝对误差方面分别较SLMGAN和WGAN-GP提升了43%和48%。此外, 前95%样本的平均绝对误差均低于0.071, 较SLMGAN提升38%, 较WGAN-GP提升49%。

2 提出的MetaDiffusion方法

2.1 扩散模型

为训练神经网络逐步去除高斯噪声并根据S参数要求生成新元原子, 首先基于扩散概率理论[39], 通过前向马尔可夫过程训练集元原子中添加噪声。从原始元原子 x_0 开始, 在每个时间步 $t \in 1, 2, \dots, T$ 上根据方差调度器 $\beta_1, \dots, \beta_T$ 添加随机噪声 e :

$$q(x_t|x_{t-1}) := \mathcal{N}\left(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I\right), \quad (1)$$

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}), \quad (2)$$

其中方差 $\beta_t \in (0, 0.02)$ 从第一个时间步 $\beta_1 = 1e-4$ 到最后一个时间步 $\beta_T = 0.02$ 线性增加,




图1: MetaDiffusion概述。(a)紫色面板: 训练过程示意图。从左至右, 展示了逐步向原始meta-atom添加噪声的过程(黑色箭头), 而从右至左, 展示了通过逐步从高斯分布样本中去噪噪声以再生meta-atom的去噪过程(绿色箭头)。(b)绿色面板: 使用神经网络近似去噪过程中所需的后验概率 $q(x_{t-1}|x_t)$ 。通过输入含噪meta-atom x_t , 预测需要去除的噪声 ϵ_θ 。S参数、额外参数和时间步长 t 作为条件被整合到神经网络中, 用于控制条件去噪。(c)蓝色面板: 按需逆向设计过程。训练有素的神经网络被用于去噪过程中, 通过从随机噪声开始并根据S参数条件进行定向去噪, 生成符合要求的新元原子。

表明数据中逐渐添加更多噪声, 使得图像最终趋近于高斯分布。通过使用重参数化技巧并定义 $\alpha_t = 1 - \beta_t$, $\alpha_t = \prod_{s=1}^t \alpha_s$, 在任意时间步 t 处的含噪元原子矩阵 x_t 可直接表示为基于 x_0 的闭式公式(详细公式推导参见补充材料第1.1节):

$$x_t = \sqrt{\alpha_t}x_0 + \epsilon\sqrt{1-\alpha_t}, \epsilon \sim \mathcal{N}(0, 1). \quad (3)$$

为了从高斯分布中的样本 x_T 中逐步去除噪声并从原始元原子分布中获得 x_0 , 需要已知后验概率 $q(x_{t-1}|x_t)$, 这是不可行的。因此, 我们使用可学习函数 $p_\theta(x_{t-1}|x_t)$ 来近似 $q(x_{t-1}|x_t)$ 。从 x_T 到 x_0 的去噪过程定义为 $p_\theta(x_{0:T})$:

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t), \quad (4)$$

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)). \quad (5)$$

在训练过程中, 我们鼓励 $p_\theta(x_{t-1}|x_t)$ 通过优化负对数似然的变分下界来近似 $q(x_{t-1}|x_t)$, 其中变分下界 L 可简化为(详细公式推导参见补充材料第1.2节):

$$E[-\log p_\theta(x_0)] \leq E_q \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} \right] := L, \quad (6)$$

$$L \propto \sum_{t>1} D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t)). \quad (7)$$

最小化KL散度可以直观理解使用神经网络 $\epsilon_\theta(x_t, t)$ 来近似估计前向过程中每个时间步添加的噪声 ϵ_t (详细公式推导见补充材料第1.3节),

$$\arg \min_{\theta} L(\theta) \propto \arg \min_{\theta} E \left[\left\| \epsilon_t - \epsilon_\theta(x_t, t) \right\|^2 \right], \quad (8)$$

其中 θ 表示神经网络的可学习参数, x_t 可从公式(3)中获得。

2.2 S参数条件的纳入

原始扩散模型用于生成与训练数据集相似的图像,但未引入生成过程的条件控制。然而,在生成元原子的任务中,必须整合S参数和附加参数(如元原子尺寸 $W1$ 、厚度 $H2$ 和材料折射率 $N2$)来控制模型的生成过程。这确保了生成的结构在特定材料、厚度和尺寸下满足S参数条件的要求。因此,我们将这些条件与时间信息 t 融合,并在训练过程中作为神经网络输入的一部分使用,表示为 $e_\theta(x_t, t, c)$ 。

此外,为了进一步提升模型的准确性,我们采用了无分类器引导策略[43]。该策略通过神经网络同时训练条件性去噪扩散模型和无条件性去噪扩散模型,作为隐式引导机制。具体而言,在训练过程中会随机抽取10%的数据样本,并用特定标签0对其对应条件进行掩码处理。完整的训练流程详见补充材料中的算法S1。

在神经网络训练完成后,在元原子的按需生成阶段,我们将条件估计 $e_\theta(x_t, t, c)$ 与无条件估计 $e_\theta(x_t, t, 0)$ 混合作为网络的噪声预测结果,其中 W 是控制准确性和多样性之间权衡的超参数。与通常关注多样性和图像质量的图像生成任务不同,元原子生成任务更强调条件准确性。因此,我们选择了一个相对较大的值 $W=6.0$ 。

$$\tilde{e}_\theta(x_t, t, c) = (1+W)e_\theta(x_t, t, c) - we_\theta(x_t, t, 0). \quad (9)$$

然后,我们对后验分布 $q(x_{t-1}|x_t, x_0)$ 进行重参数化技巧,并代入噪声 $\tilde{e}_\theta(x_t, t, c)$ 通过神经网络近似,从前一时间步获取图像(详细公式推导参见补充材料第1.4节):

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \tilde{e}_\theta(x_t, t, c) \right) + \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \cdot \beta_t \cdot z, \quad (10)$$

其中 $z \sim N(0,1)$ 。

通过迭代去噪过程,可生成符合S参数要求的新元原子。按需生成阶段的完整流程详见补充材料中的算法S2。

2.3 网络体系结构

如图2所示,我们采用通用的编码器-解码器U-Net架构来预测给定噪声图像 x_t 的噪声 e 。这使我们能够近似后验概率 $q(x_{t-1}|x_t)$,并随后通过公式(10)获得 x_{t-1} 。该网络由一组编码器组成,这些编码器包含用于下采样压缩的残差块和池化层,随后使用转置卷积和残差块进行上采样恢复。在压缩和恢复过程中提取关键特征。编码器与解码器通过跳跃连接相连,以减轻编码器下采样过程中的信息损失。

此外,考虑到元原子生成任务的复杂性,我们采用两个全连接层从S参数、附加参数及时间步 t 中提取特征。这些提取的特征随后被拼接并整合到解码器的上采样过程中,确保了低计算复杂度和条件的有效融合。(具体网络结构和训练超参数参见补充材料)

3 结果与讨论

为验证和比较模型性能,我们使用全介电自由形态单元胞数据集[45]。如图1所示,每个单元胞由两层不同折射率的介电层组成:上层为关于XY轴对称的高折射率自由形态结构,下层为固定折射率 $N1=1.4$ 且厚度为 $H1=2 \text{ \AA m}$ 的结构。整个单元胞结构可通过 64×64 二进制矩阵(0代表空气,1代表介电层)表征自由形态结构的形状,以及 1×3 参数矩阵表征基底尺寸 $W1$ 。[2.5 $\text{\AA m}$, 3 $\text{\AA m}$],厚度 $H2$ 。[0.5 $\text{\AA m}$, 1 $\text{\AA m}$],以及折射率 $N2$ 。[3.5, 5]。该数据集假设所有元原子均与极化无关且互为对称,具有对称构型。这使得我们可以将结构表示简化为左上角的 32×32 二维矩阵,从而引入物理




图2: MetaDiffusion网络架构。输入 x_t 首先通过由残差块（Resblock）和池化层组成的编码器进行下采样，这会缩小矩阵尺寸同时增加特征通道的深度。在瓶颈层，输入被转换为512维向量。随后通过由多个转置卷积层（Tconv）和残差块组成的解码器，逐步减少通道数量并恢复尺寸。编码器与解码器之间存在跳跃连接以保留信息。S参数与附加参数被拼接成条件向量。该条件向量与时间步信息分别通过由全连接层（Linear）组成的特征提取器处理后，再输入解码器。最终，网络预测出与输入尺寸相同的噪声 ϵ_θ 。

将对称性作为先验知识预先输入，有利于网络训练。然而，未来我们计划利用MetaDifusion模型生成具有更复杂特性的元原子，例如手性超材料或非厄米超材料。

通过 CST Microwave Studio 模拟结构获得的 30 至 60 THz 传输响应被用作结构数据的标签。传输响应的实部和虚部分别以 26 个采样点进行采样，并组合成一个 1×52 的一维向量来表示传输响应。此外，我们引入 1×3 个结构参数 $[W1, H2, N2]$ 作为附加条件，从而增加一个约束条件，引导模型生成具有所需材料、结构尺寸和厚度的元原子。最终，我们将 1×3 参数向量与 1×52 传输响应拼接，形成 1×55 向量作为生成网络输入的目标条件。该数据集包含 174,883 个数据点，并按 8:1:1 的比例划分为训练集、验证集和测试集。

在训练和比较生成式神经网络的过程中，模型被要求为验证集和测试集上的 S 参数目标生成结构。随后，需要对生成的结果进行正向模拟以获得相应的频率响应，从而定量评估网络的准确性表现。然而，使用数值

诸如时域有限差分（FDTD）等模拟方法耗时极长，其运算速度远不及生成网络的生成速率。在神经网络的训练和测试过程中，处理海量数据的评估工作难度较大。为此，我们选择采用预测神经网络（PNN）[45]作为快速求解器，以毫秒级精度准确预测单元胞的频谱响应。通过定性和定量实验验证，PNN 可作为可靠的替代求解器。PNN 在测试集上的均方误差（MSE）为实部 0.001835、虚部 0.001789。（更多实验结果详见补充材料）

为充分验证本文提出方法在按需直接生成能力方面的准确性和稳定性，我们将其与当前最先进的按需直接生成元原子的方法进行比较，包括 WGAN -GP[28]、SLMGAN 模拟器 [44] 和条件 VAE（cVAE）[22]。(1) WGAN -GP 通过采用梯度惩罚方法限制近似 Wasserstein 距离的网络参数，从而增强 WGAN 的稳定性。(2) 最近提出的 SLMGAN 模拟器（以下简称 SLMGAN）通过采用 Sinkhorn 迭代显式计算最优传输，并将预训练的前向预测网络作为训练的一部分，进一步增强了训练稳定性和条件准确性。

(3)cVAE是一种基于VAE的代表性方法,它利用S参数条件作为解码器的输入,使得VAE能够直接生成元原子。

(有关SLMGAN模拟器、WGAN-GP和cVAE的实现细节,请参阅补充材料)

将四种模型生成的结果进行二值化处理(以0.5为阈值,将小于0.5的值设为0,大于或等于0.5的值设为1)后,采用代理求解器对这些结果进行正向计算以获得相应的S参数。均方绝对误差(MAE)被用作每个样本准确性的误差指标,其中每个样本的MAE表示为:

$$L = \frac{1}{n} \sum_{i=1}^n |s_{\text{target}}(i) - s_{\text{gen}}(i)|, \quad (11)$$

where $s_{\text{target}}(i)$ 是第*i*频率点的目标S参数, $s_{\text{gen}}(i)$ 是第*i*频率点生成结果对应的S参数。上述计算包括实部和虚部的26个点。

在训练过程中,每个训练周期结束时,我们使用当前周期的模型参数根据S参数条件在验证集上生成样本,并评估每个生成样本相对于输入条件的平均绝对误差(MAE)。通过计算所有样本的MAE损失均值,可得出当前周期下生成结果在整个验证集上的准确率。整个训练过程中三种方法在验证集上的MAE结果如图3所示。四种方法均在500个周期内逐渐收敛,其中MetaDiffusion收敛至约0.03,SLMGAN、WGAN-GP和cVAE方法分别收敛至约0.05、0.05和0.06。更重要的是,从图中可以看出我们的方法收敛速度显著快于SLMGAN和WGAN-GP。




图3: 四个模型在训练过程中的验证损失。

具体而言,MetaDiffusion在前14个训练周期收敛至0.068,前30个周期收敛至0.052,表明我们的方法比基于GAN的方法更稳定、更易训练,且在达到相同效果时所需训练时间更短。尽管cVAE的收敛速度与MetaDiffusion相似,但其收敛误差高于MetaDiffusion和基于GAN的方法,这表明其学习能力较弱。

随后,我们使用四个训练好的模型对测试集上的模型性能进行定性和定量对比。在图4和图5中,随机选取了四个模型的生成结果进行定性展示。每行代表一种方法,从上到下依次为:MetaDiffusion、SLMGAN、WGAN-GP和cVAE。针对每种方法,图中展示了数据集中的原始结构、模型的直接输出结果以及二值化后的结构。最后,通过前向模拟二值化结构,将生成结构的S参数与目标S参数进行对比。从图中可以看出,三种方法都能生成大致符合目标S参数趋势的结构,且均满足所需的S参数条件。然而,在三种方法中,我们提出的MetaDiffusion方法具有最高的准确率,而SLMGAN、WGAN-GP和cVAE在某些频率范围内存在不准确现象。虽然我们以二值化后的结果作为模型输出,但直接观察模型输出仍能一定程度上反映其生成能力和稳定性。如图所示,MetaDiffusion可直接生成清晰的结构图像,而WGAN-GP因对抗过程导致的训练不稳定性,在生成结果中存在一定程度的模糊现象。SLMGAN因其采用特殊插值操作作为引入对称性信息的方式,进一步影响了生成结果的清晰度。cVAE同样容易生成模糊图像,这是由于VAE在训练过程中需要平衡图像重建误差与潜在空间与标准分布之间的KL散度。这种固有缺陷限制了cVAE生成稳定且均匀的模式。

此外,如图4和图5所示,我们提出的方法倾向于产生更均匀的结构,而其他三种方法生成的结构偶尔会出现像素分散的情况,这使得制造过程变得复杂。为进一步证明我们的方法在生成稳定结构方面的优势,特别是在制造便捷性方面,我们采用该方法对特定目标进行一对多代际生成,如图6所示。




图4: 按需逆向设计定性对比示例1。(a)MetaDiffusion生成结果。(b) SLMGAN 模拟器生成结果。(c) WGAN -GP生成结果。(d) cVAE生成结果。针对每种方法, 我们分别展示原始数据集结构(原始数据)、模型直接输出(模型输出)及二值化处理结果(二值化后)。通过二值化结构的正向模拟, 获取对应S参数的实部(生成实部)与虚部(生成虚部), 并与目标S参数的实部(目标实部)和虚部(目标虚部)进行对比。各频率点的实部误差(误差实部)与虚部误差(误差虚部)以柱状图形式呈现。需注意, 图中灰色区域表示蓝色与橙色区域的重叠部分。

图7从定量角度对比了四种模型在S参数条件下生成单元胞的准确性, 数据来源于整个测试集。图7a展示了整个测试集的平均MAE值。MetaDifusion在测试集上的平均误差为0.02824, 显著低于 SLMGAN (0.04955)、WGAN -GP (0.05454) 和 cVAE (0.06142) 的平均误差。这表明MetaDifusion作为元原子逆向设计模型比其他三种模型更有效。具体而言, MetaDifusion的准确率分别较 SLMGAN、WGAN -GP和cVAE提升了43%、48%和54%。

除了关注平均误差情况外, 我们还特别关注样本误差的分布情况, 以避免某些样本表现优异而掩盖大多数样本在平均指标上的较差表现。我们计算了四个模型在完整测试集上每个样本的误差。如图7b的误差分布图所示, 绿色、蓝色、橙色和紫色柱状图分别表示MetaDifusion、SLMGAN、WGAN -GP和cVAE在对应误差范围内的占比; 实线表示

通过在模型分布上应用核密度估计(KDE)数据平滑方法, 可直观呈现分布的整体趋势。从图7b可以看出, 我们提出的方法误差分布更集中于0附近, 而 SLMGAN、WGAN -GP和cVAE的误差分布则更为均匀。图中用虚线标出了各模型95%样本误差的位置。在我们提出的MetaDifusion模型中, 95%样本的误差优于0.071, 而 SLMGAN、WGAN -GP和cVAE的95%误差分别为0.115、0.139和0.166。因此, 就前95%样本的误差而言, 我们的方法较 SLMGAN、WGAN -GP和cVAE分别提升了38%、49%和57%。

最后, 我们还比较了模型在训练数据量减少情况下的性能表现。如图8所示, 我们将训练集规模分别限制为原始训练集的80%、60%、40%和20%。测试集结果如图8所示。从结果可以看出, 随着训练数据集规模的减小, 所有四种方法的性能均有所下降。然而, MetaDifusion




图5: 按需逆向设计的定性对比示例2。(a)MetaDiffusion生成的结果。(b) SLMGAN 模拟器生成的结果。(c) WGAN -GP生成的结果。(d)cVAE生成的结果。




图6: 一到多代结构。图(a)和(b)展示了两组示例, 其中生成了多个满足给定S参数的目标单元结构(每幅图顶部)。可以看出, MetaDiffusion倾向于生成易于制造的规则结构。




图7: 四种方法的定量对比。(a)测试集上的平均MAE误差。MetaDiffusion相对于模拟器SLMGAN、WGAN-GP和cVAE的改进如图中箭头所示。(b)测试集上的误差分布。垂直虚线表示95%误差对应的点。




图8: 有限训练数据下的测试损失。四个模型分别使用训练数据集的100%、80%、60%、40%和20%进行训练,并在完整测试数据集上进行测试。

该方法始终优于其他三种方法,证明了其在有限样本量下的性能优势。

4 结论

最后,我们提出了一种基于扩散概率理论的元曲面逆向设计方法MetaDiffusion,该方法能够直接生成符合宽带幅相要求的高质量、多样化和精确的自由曲面元原子。通过采用神经网络学习噪声扩散过程,我们的方法生成了符合要求的新元原子

通过去噪处理S参数条件,从而避免了劳动密集型的传统迭代搜索过程。

实验表明,在近期人工智能领域按需直接生成元原子的VAE中,广泛使用的生成对抗网络(GAN)系列方法具有更高的准确率优势。然而,由于对抗训练过程的存在,GAN模型本身存在固有的不稳定性。相比之下,我们的方法无需经历对抗训练过程,因此不存在模型不稳定的困扰。这种特性使得我们的方法无需通过多次实验来为不同场景选择稳定的网络结构,既可轻松扩展至多种应用场景,又能确保生成元原子的准确性和高质量。实验验证显示,MetaDiffusion在模型收敛速度、生成结构质量和准确率方面均优于代表性GAN方法。

MetaDiffusion方法论为逆向设计开辟了新方向,推动了扩散概率模型在元原子设计领域的深入探索。后续研究中,我们将充分发挥扩散概率模型固有的卓越条件精度优势,开发并制造复杂的自由曲面元表面,以满足现实场景中复杂应用的需求。

研究经费: 本研究获得中国国家重点研发计划(2020YFB1806405和2020YFB1806400)和PCL重大项目(PCL2023AS2-4)的支持。

作者贡献: 张泽洲: 概念化、方法论、软件开发、初稿撰写、审阅与编辑; 杨传川: 审阅与编辑、监督、资金获取; 秦一峰: 初稿撰写、审阅与编辑; 冯浩: 可视化; 冯继强: 审阅与编辑、资源获取、资金获取; 李洪斌: 监督、资金获取。所有作者均对本手稿的全部内容负责并同意提交。

利益冲突: 作者声明无利益冲突。**数据可用性:** 本研究使用的数据集可在开源存储库<https://github.com/SensorAn/Meta-atoms-data-sharing>获取。

参考文献

- [1] Q. 何、孙帅、肖帅和周立, “高效超表面: 原理、实现与应用”, *先进光学材料*, 第6卷, 第19期, 第1800415页, 2018年。
- [2] S. 陈、W. 刘、Z. 李、H. 常和 J. 田, “超表面赋能的光学复用与多功能性”, *Adv. Mater.*, 第32卷, 第3期, 第1805912页, 2020年。
- [3] M. Khorasaninejad与F. Capasso合著的《基于介质波导相移器的宽带多功能高效超晶格》发表于《*纳米快报*》2015年第15卷第10期, 第6709-6715页。
- [4] 李Z、佩斯图里R、朴J-S、黄Y-W、约翰逊S-G及F. Capasso, “逆向设计实现大规模高性能元光学重塑虚拟现实”, *Nat. Commun.*, 第13卷, 第1期, 第2409页, 2022年。
- [5] G. Hu, W. Ma, D. Hu, 等人, 《单斜晶系晶体中双曲剪切极化激元的实空间纳米成像》, 《*自然·纳米技术*》, 第18卷, 第1期, 第64-70页, 2023年。
- [6] S. Dong, G. Hu, Q. Wang 等, 《损耗辅助超表面在例外点的应用》, *ACS Photonics*, 第7卷, 第12期, 第3321-3327页, 2020年。
- [7] O. Khatib, S. Ren, J. Malof, 和 W. J. Padilla, “深度学习超材料的电磁特性——综述”, *Adv. Funct. Mater.*, 第31卷, 第31期, 第2101748页, 2021年。
- [8] J. Jensen与O. Sigmund合著的《拓扑优化》*纳米光子学“激光光子学评论”*, 第5卷, 第2期, 第308-321页, 2011年。
- [9] S. Jafar-Zanjani、S. Inampudi与H. Mosallaei合著的《光学超表面设计的自适应遗传算法》, 发表于《*科学报告*》(Sci. Rep.) 2018年第8卷第1期第11040页。
- [10] A. Lewis、G. Weis、M. Randall、A. Galehdar和D. Thiel在《利用蚁群系统优化小型蜿蜒线RFID天线的效率与增益》一文中指出, 该研究发表于2009年IEEE进化计算大会, 由IEEE主办, 论文编号1486-1492。
- [11] J. Jiang与J. A. Fan, 《基于物理驱动神经网络的介电超表面全局优化》, *Nano Lett.*, 第19卷第8期, 第5366-5372页, 2019年。
- [12] X. An, Y. Cao, Y. Wei, 等, “基于深度神经网络的宽带消色差金属透镜设计”, *Opt. Lett.*, 第46卷, 第16期, 第3881-3884页, 2021年。
- [13] S. An、C. Fowler、B. Zheng 等, 《基于深度学习的全介电超表面设计方法》, *ACS Photonics*, 第6卷, 第12期, 第3196-3207页, 2019年。
- [14] D. Liu、Y. Tan、E. Khoram和Z. Yu, 《用于纳米光子结构逆向设计的神经网络训练》, *ACS Photonics*, 第5卷, 第4期, 第1365-1369, 2018。
- [15] L. Yuan、L. Wang、X.-S. Yang、H. Huang 和 B.-Z. Wang, “一种用于超表面逆向设计的高效人工神经网络模型”, *IEEE天线与无线传播快报*, 第20卷, 第6期, 第1013-1017页, 2021年。
- [16] C. Yeung, J.-M. Tsai, B. King 等人, “采用串联残差网络的多路复用超表面设计与优化”, *纳米光子学*, 第10卷, 第3期, 第1133-1143页, 2021年。
- [17] I. Goodfellow、J. Pouget-Abadie、M. Mirza 等, 《生成对抗网络》, 载于《*神经信息处理系统进展*》第27卷, 蒙特利尔会议宫, 加拿大蒙特利尔, Curran Associates, Inc, 2014年, 第2672-2680页。可获取于:
https://papers.nips.cc/paper_files/paper/2014/hash/5ca3e9b122f61f8f06494c97b1afcf3-Abstract.html。
- [18] D. P. Kingma 与 M. Welling, 《自编码变分贝叶斯》, 2013年, arXiv预印本 arXiv:1312.6114。
- [19] Z. Xiao、K. Kreis 和 A. Vahdat, 《利用去噪扩散生成对抗网络解决生成学习三难困境》, 2021年, arXiv预印本 arXiv:2112.07804。
- [20] I. 坦里奥弗、D. 李、W. 陈和 K. 艾丁, 《可制造自由曲面介电超表面的深度生成建模与逆向设计》, *ACS Photonics*, 第10卷, 第875-883页, 2022年。
- [21] M. Zandehshahvar、Y. Kiarashinejad、M. Zhu、H. Maleki、T. Brown和A. Adibi, 《基于流形学习的知识发现与光子纳米结构智能逆向设计: 突破几何复杂性》, *ACS Photonics*, 第9卷第2期, 第714-721页, 2022年。
- [22] W. Ma, F. Cheng, Y. Xu, Q. Wen, 和 Y. Liu, “基于半监督学习策略的深度生成模型的超材料概率表示与逆向设计”, *Adv. Mater.*, 第31卷, 第35期, 第1901111页, 2019年。
- [23] M. Mirza 和 S. Osindero, 《条件生成对抗网络》, 2014年, arXiv 预印本 arXiv:1411.1784。
- [24] Z. Liu、D. Zhu、S. P. Rodrigues、K.-T. Lee 和 W. Cai, “用于元表面逆向设计的生成模型”, *Nano Lett.*, 第18卷, 第10期, 第6570-6576页, 2018年。
- [25] S. So和J. Rho在《*纳米光子学*》第8卷第7期(2019年)发表的论文《基于条件深度卷积生成对抗网络的纳米光子结构设计》中, 详细阐述了相关技术方案。
- [26] H. P. 王, Y. B. 李H. 李等人, 《基于生成对抗网络的超宽带各向异性超表面深度学习设计》, *先进智能系统*, 第2卷, 第9期, 2000068页, 2020年。
- [27] C. Yeung, R. Tsai, B. Pham 等人, “利用生成式深度学习跨多种光子结构类别的全局逆向设计”, *Adv. Opt. Mater.*, 第9卷, 第20期, 第2100548页, 2021年。
- [28] J. Jiang、D. Sell、S. Hoyer、J. Hickey、J. Yang和J. A. Fan, 《基于生成对抗网络的自由形式衍射元设计》, *ACS Nano*, 第13卷, 第8期, 第8872-8878页, 2019年。
- [29] F. Wen、J. Jiang和J. A. Fan, 《基于渐进式生成网络的鲁棒自由曲面超表面设计》, *ACS Photonics*, 第7卷, 第8期, 第2098-2104页, 2020年。
- [30] 刘P、陈L与陈ZN合著的《基于先验知识的

- 金属透镜天线中的移位范围超元胞, *IEEE Trans. Antennas Propag.*, 第70卷, 第7期, 第5024-5034页, 2022年。
- [31] A. Baucour, M. Kim和J. Shin发表的《基于条件生成对抗网络的数据驱动并行纳米结构优化》, *《纳米光子学》*第11卷第12期, 2865-2873页, 2022年。
- [32] P. Dai, K. Sun, X. Yan 等人, 《结构色彩的逆向设计: 通过条件生成对抗网络寻找多个解决方案》, *《纳米光子学》*, 第11卷, 第13期, 第3057-3069页, 2022年。
- [33] S. An, B. Zheng, H. Tang 等, “基于生成对抗网络的多功能超表面设计”, *Adv. Opt. Mater.*, 第9卷, 第5期, 2001433页, 2021年。
- [34] A. Radford, L. Metz and S. Chintala, 《基于深度卷积生成对抗网络的无监督表征学习》, 2015年, arXiv 预印本 arXiv: 1511.06434。
- [35] M. Arjovsky, S. Chintala和L. Bottou, 《Wasserstein生成对抗网络》, *国际机器学习会议*, PMLR, 2017年, 第214-223页。
- [36] I. 古拉贾尼, F. 阿赫迈德, M. 阿尔若夫斯基, V. 杜穆兰和 A. C. Courville, “改进的瓦瑟斯坦训练”, *Adv. Neural Inf. Process. Syst.*, 第30卷, 第5767-5777页, 2017年。
- [37] Z. Li, R. Pestourie, Z. Lin, S. G. Johnson和F. Capasso, 《通过逆向设计增强元表面: 原理与应用》, *ACS Photonics*, 第9卷, 第7期, 第2178-2192页, 2022年。
- [38] P. Dhariwal与A. Nichol在《扩散模型胜过GAN进行图像合成》一文中指出, 该研究发表于《先进神经信息处理系统》第34卷第8780-8794页(2021年)。
- [39] J. Ho, A. Jain 和 P. Abbeel, 《去噪扩散概率模型》, *先进神经信息处理系统*, 第33卷, 第6840-6851页, 2020年。
- [40] A. Ramesh, M. Pavlov, G. Goh 等人, 《零样本文本到图像生成》, *国际机器学习会议*, PMLR, 2021年, 第8821-8831页。
- [41] C. Saharia, W. Chan, S. Saxena, 等, “具有深度语言理解的逼真文本到图像扩散模型”, *Adv. Neural Inf. Process. Syst.*, 第35卷, 第36479-36494页, 2022年。
- [42] C. 萨哈里亚, J. 霍, W. 陈, T. 萨利曼斯, D. J. 弗利特和 M. Norouzi, “通过迭代精炼实现图像超分辨率”, *IEEE 模式分析与机械智能汇刊*, 第45卷, 第4713-4726页, 2022年。
- [43] J. Ho和T. Salimans, 《无分类器扩散引导》, 收录于 *NeurIPS 2021 Deep Generative 模型与 Downstream Applications 研讨会*, 2021。
- [44] 戴先生、江宇、杨峰等人, “Simgan: 基于生成对抗网络的对称自由形态单层超表面设计”, *应用软件计算*, 第130卷, 第109646页, 2022年。
- [45] S. An, B. Zheng, M. Y. Shalaginov 等, “高自由度超曲面的深度学习建模方法”, *Opt. Express*, 第28卷, 第21期, 第31932-31942页, 2020年。

补充材料: 本文包含补充材料

(<https://doi.org/10.1515/nanoph-2023-0292>)。